

IFT 3515
Fonctions à plusieurs variables
Optimisation sans contraintes
Gradient conjugué

Fabian Bastin
DIRO
Université de Montréal

Méthode du gradient conjugué

- Proposé par Hestenes et Stiefel en 1952 (comme méthode directe).
- Cette méthode peut être utilisée quand les exigences mémoire des méthodes quasi-Newton dépassent la mémoire machine disponible, ou alternativement pour résoudre des systèmes d'équations linéaires définis positifs.
- De plus, elle est particulièrement adaptée pour résoudre le sous-problème quadratique en région de confiance.
- Note: ces transparents se sont fortement inspirés du cours donné en 2006 par Raphael Hauser à Oxford.

Motivations: exigences mémoire

- L'utilisation de la mémoire dans un ordinateur a longtemps été un sujet de préoccupation en raison du coût de celle-ci et de sa capacité limitée. Aujourd'hui, des défis demeurent comme les modèles peuvent être de grandes tailles, avec plusieurs millions de variables.
- Supposons que nous avons n variables. **Décomposition spectrale**: Les méthodes quasi-Newton doivent maintenir en mémoire une matrice de dimensions $n \times n$, représentant une approximation de la matrice hessienne ou de son inverse, ou le facteur de Cholesky de cette matrice. Dans tous les cas, le coût de stockage est en $O(n^2)$.
- La méthode de plus forte pente a seulement des besoins mémoire en $O(n)$, pour stocker x_k et $\nabla f(x_k)$, et peut donc traiter des problèmes de plus grandes tailles, mais a tendance à exiger beaucoup plus d'itérations pour converger.

Propriétés du gradient conjugué

La méthode du gradient conjugué a

- une consommation mémoire en $O(n)$,
- une complexité de calcul en $O(n)$ par itération,
- mais converge plus rapidement que la méthode de plus forte pente.

Minimisation de fonctions quadratiques

Soit $B \succ 0$ et considérons le problème

$$\min_{x \in \mathcal{R}^n} f(x) = \frac{1}{2} x^\top B x + b^\top x + a.$$

Puisque f est convexe, $\nabla f(x) = 0$ est une condition d'optimalité suffisante. Dès lors, ce problème d'optimisation est équivalent à résoudre le système linéaire défini positif

$$Bx = -b$$

qui a pour solution

$$x^* = -B^{-1}b.$$

Motivation géométrique

Ajouter une constante à la fonction objectif du problème

$$\min_{x \in \mathcal{R}^n} f(x) = \frac{1}{2}x^\top Bx + b^\top x + a.$$

ne change pas le minimiseur global $x^* = -B^{-1}b$. Dès lors, le problème est équivalent à

$$\min_{x \in \mathcal{R}^n} f(x) = \frac{1}{2}(x - x^*)^\top B(x - x^*).$$

En effet,

$$\begin{aligned} \frac{1}{2}(x - x^*)^\top B(x - x^*) &= \frac{1}{2}x^\top Bx + \frac{1}{2}(x^*)^\top Bx^* - 2\frac{1}{2}(x^*)^\top Bx \\ &= \frac{1}{2}x^\top Bx + \frac{1}{2}(x^*)^\top Bx^* + b^\top (B^{-1})^\top Bx \\ &= \frac{1}{2}x^\top Bx + \frac{1}{2}(x^*)^\top Bx^* + b^\top x \end{aligned}$$

Motivation géométrique

Nous pouvons encore réécrire le problème comme

$$\min_{x \in \mathcal{R}^n} f(x) = \frac{1}{2}(x - x^*)^T B(x - x^*) = \frac{1}{2}y^T y = g(y),$$

où $y = B^{1/2}(x - x^*)$. Dès lors le problème d'optimisation apparaît particulièrement simple en termes de y .

Note: soit une matrice $A \in \mathcal{R}^{n \times n}$ symétrique.

- A a n valeurs propres réelles $\lambda_1 \leq \dots \leq \lambda_n$ et il existe une matrice orthogonale Q (i.e. $QQ^T = Q^T Q = I$) telle que $A = Q \text{diag}(\lambda) Q^T$
- $A^{-1} = Q D^{-1} Q^T$, i.e., A est non-singulière ssi $\forall i, \lambda_i \neq 0$
- A est définie positive ssi $\forall i, \lambda_i > 0$, et alors $A^{1/2} := Q \text{diag}(\lambda^{1/2}) Q^T$ est l'unique matrice symétrique définie positive telle que $A^{1/2} A^{1/2} = A$.

Principes généraux

Nous souhaitons construire une séquence itérative $\{x_k\}_{k \in \mathcal{N}}$ telle que la séquence correspondante $\{y_k\}_{k \in \mathcal{N}} = \{B^{1/2}(x_k - x^*)\}_{k \in \mathcal{N}}$ se comporte de manière appropriée.

Considérons l'itéré courant x_k appliquons une recherche linéaire exacte

$$\begin{aligned}\alpha_k &= \arg \min_{\alpha} f(x_k + \alpha_k d_k) \\ &= \arg \min_{\alpha} \frac{1}{2} (x_k + \alpha_k d_k - x^*)^T B (x_k + \alpha_k d_k - x^*)\end{aligned}$$

à partir de x_k dans la direction d_k .

Principes généraux

Comme B est définie positive, il s'agit d'un problème univarié strictement convexe, et la solution peut se calculer en annulant la dérivée par rapport à α :

$$\begin{aligned} 0 &= \frac{d}{d\alpha} f(x_k + \alpha_k d_k) = \nabla_x f(x_k + \alpha_k d_k)^T \frac{d}{d\alpha} (x_k + \alpha_k d_k) \\ &= (B(x_k + \alpha_k d_k) + b)^T d_k \\ &= (x_k + \alpha_k d_k)^T b^T d_k + b^T d_k \\ &= x_k^T b^T d_k + \alpha_k d_k^T b^T d_k + d_k^T b \\ &= \alpha_k d_k^T B d_k + d_k^T (B x_k + b) \\ &= \alpha_k d_k^T B d_k + d_k^T \nabla_x f(x_k) \end{aligned}$$

et donc

$$\alpha_k = -\frac{d_k^T \nabla f(x_k)}{d_k^T B d_k}.$$

Principes généraux

En termes de y_k , cela donne

$$\begin{aligned}\alpha_k &= \arg \min_{\alpha} g(y_k + \alpha p_k) \\ &= \arg \min_{\alpha} \frac{1}{2} (y_k + \alpha p_k)^T (y_k + \alpha p_k) \\ &= \arg \min_{\alpha} \frac{1}{2} \|y_k\|^2 + \alpha p_k^T y_k + \frac{1}{2} \alpha^2 \|p_k\|^2,\end{aligned}$$

dont la solution est

$$\alpha_k = -\frac{p_k^T y_k}{\|p_k\|^2}.$$

De plus, si nous posons $y_{k+1} = y_k + \alpha_k p_k$, nous avons

$$\begin{aligned}y_{k+1} &= B^{1/2}(x_{k+1} - x^*) = B^{1/2}(x_k + \alpha_k d_k - x^*) = B^{1/2}(x_k - x^*) + \alpha_k B^{1/2} d_k \\ &= y_k + \alpha_k B^{1/2} d_k.\end{aligned}$$

Principes généraux

Nous pouvons ainsi retrouver la solution précédente en prenant $p_k = B^{1/2}d_k$. En particulier, alors,

$$\begin{aligned}\alpha_k &= -\frac{p_k^T y_k}{\|p_k\|^2} \\ &= -\frac{d_k^T B^{1/2} B^{1/2} (x_k - x^*)}{d_k^T B d_k} \\ &= -\frac{d_k^T (Bx_k - Bx^*)}{d_k^T B d_k} \\ &= -\frac{d_k^T (Bx_k + b)}{d_k^T B d_k} \\ &= -\frac{d_k^T \nabla_x f(x_k)}{d_k^T B d_k}.\end{aligned}$$

Directions conjuguées

Remarquons que

$$y_{k+1}^T p_k = y_k^T p_k + \alpha_k p_k^T p_k = y_k^T p_k - \frac{p_k^T y_k}{\|p_k\|^2} \|p_k\|^2 = 0.$$

Autrement dit, y_{k+1} est orthogonal à p_k , et ceci indépendamment de la localisation de x_k .

Comme $y_{k+1} = B^{1/2}(x_{k+1} - x^*)$, nous avons aussi

$$(x_{k+1} - x^*)^T B^{1/2} p_k = 0$$

et donc

$$x_{k+1} \in \pi_k := x^* + B^{-1/2} p_k^\perp$$

Directions conjuguées

Plus généralement, la résolution du problème

$$\alpha^* = \arg \min_{\alpha} f(x + \alpha d)$$

dans la direction $d = \pm d_k$ conduit à un point $x^+ = x + \alpha^* d$ dans l'hyperplan π_k , aussi nous ne devrions plus sortir de π_k à partir de l'itération $k + 1$.

L'exigence que toutes les itérations ultérieures à l'itération k doivent être conduites à l'intérieur de π_k mènent à la condition

$$p_j \perp p_k$$

pour tout $j > k$, ou, de manière équivalente, pour tout $j \geq k + 1$,

$$d_k^T B d_j = 0.$$

Directions conjuguées

Definition (Directions conjuguées)

Deux vecteurs d_i, d_j sont B -conjugués si

$$d_i^T B d_j = 0 \quad (i \neq j)$$

Ceci revient à affirmer l'orthogonalité des vecteurs d_i et d_j par rapport au produit scalaire euclidien défini par B .

En répétant l'argumentation à partir de l'itération $k + 2$, on peut affirmer que x_j appartiendra à l'hyperplan π_{k+1} pour $j \geq k + 2$.

Il suit que la dimension de l'espace de recherche π_k diminue de 1 à chaque itération, aussi l'algorithme se termine après n itérations.

Dès lors, nous devons choisir des directions de recherche mutuellement B -conjuguées.

Convergence

Théorème

Soit

$$f(x) := \frac{1}{2}x^\top Bx + b^\top x + a,$$

où $B \succ 0$. Pour $k = 0, \dots, n-1$, soit d_k choisi tel que

$$d_i^\top B d_j = 0, \quad \forall i \neq j.$$

Soient $x_0 \in \mathcal{R}^n$ et

$$x_{k+1} = x_k + \alpha_k d_k$$

pour $k = 0, \dots, n-1$, où

$$\alpha_k = \arg \min_{\alpha} f(x_k + \alpha d_k)$$

Alors x_n est le minimiseur global de f .

Directions

Comment choisir des directions de recherche B -conjuguées?

Lemme (Orthogonalisation de Gram-Schmidt)

Soient $v_0, \dots, v_{n-1} \in \mathcal{R}^n$ des vecteurs linéairement indépendants, et soient $d_0, \dots, d_{n-1}$ définis récursivement comme

$$d_k = v_k - \sum_{j=0}^{k-1} \frac{d_j^T B v_k}{d_j^T B d_j} d_j.$$

Alors $d_i^T B d_k = 0$ pour tout $i \neq k$.

Directions

Preuve.

Induction sur k .

- Pour $k = 0$, il n'y a rien à prouver.
- Supposons que

$$d_i^T B d_j = 0$$

pour tout $i, j \in \{0, \dots, k-1\}$, $i \neq j$.

- Pour $i < k$,

$$d_i^T B d_k = d_i^T B v_k - d_i^T B \sum_{j=0}^{k-1} \frac{d_j^T B v_k}{d_j^T B d_j} d_j = d_i^T B v_k - d_i^T B v_k = 0$$

- L'indépendance linéaire des v_j garantit qu'autant des d_j n'est nul, et dès lors $d_j^T B d_j > 0$ pour tout j .

Plus forte pente

Malheureusement, cette procédure exigerait de stocker les vecteurs d_j ($j < k$) en mémoire, aussi la méthode consommerait un espace mémoire en $O(n^2)$.

Nous pouvons conserver une exigence de stockage en $O(n)$ si nous choisissons pour v_k la direction de plus forte pente.

Lemme (Orthogonalité)

Choisissons $d_0 = -\nabla f(x_0)$ et pour $k = 1, \dots, n-1$, calculons d_k comme

$$d_k = -\nabla f(x_k) - \sum_{j=0}^{k-1} \frac{d_j^T B(-\nabla f(x_k))}{d_j^T B d_j} d_j.$$

Alors $\nabla f(x_j)^T \nabla f(x_k) = 0$ et $d_j^T \nabla f(x_k) = 0$ pour $j < k$.

Plus forte pente

Preuve.

Notons que $\nabla f(x_k) = Bx_k + b$ pour tout k .

Par induction sur k , prouvons que $d_j^T \nabla f(x_k) = 0$ pour $j < k$.

- C'est évident pour $k = 0$. Supposons que le résultat tient pour k . Alors, pour $j = 0, \dots, k - 1$,

$$\begin{aligned} d_j^T \nabla f(x_{k+1}) &= d_j^T (Bx_{k+1} + b) \\ &= d_j^T (B(x_k + \alpha_k d_k) + b) \\ &= d_j^T \nabla f(x_k) + \alpha_k d_j^T B d_k \\ &= 0. \end{aligned}$$

- De plus, $d_k^T \nabla f(x_{k+1}) = 0$ est la condition d'optimalité de premier ordre pour la recherche linéaire $\min_{\alpha} f(x_k + \alpha d_k)$, définissant x_{k+1} .

Plus forte pente

Preuve.

La définition de d_k implique que, pour tout k ,

$$\text{span}(d_0, \dots, d_k) = \text{span}(\nabla f(x_0), \dots, \nabla f(x_k)).$$

Pour $j < k$, il existe dès lors certains $\lambda_1, \dots, \lambda_j$ tels que

$$\nabla f(x_j) = \sum_{i=0}^j \lambda_i d_i,$$

et nous avons

$$\nabla f(x_j)^T \nabla f(x_k) = \sum_{i=0}^j \lambda_i d_i^T \nabla f(x_k) = 0.$$

Mise à jour des directions

Rappelons que

$$d_k = -\nabla f(x_k) - \sum_{j=0}^{k-1} \frac{d_j^T B(-\nabla f(x_k))}{d_j^T B d_j} d_j.$$

Comme $\nabla f(x_k) = Bx_k + b$,

$$\nabla f(x_{j+1}) - \nabla f(x_j) = B(x_{j+1} - x_j) = B(x_j + \alpha_j d_j - x_j) = \alpha_j B d_j.$$

Dès lors

$$\begin{aligned} d_k &= -\nabla f(x_k) - \sum_{j=0}^{k-1} \frac{(\nabla f(x_{j+1}) - \nabla f(x_j))^T (-\nabla f(x_k))}{(\nabla f(x_{j+1}) - \nabla f(x_j))^T d_j} d_j \\ &= -\nabla f(x_k) + \sum_{j=0}^{k-1} \frac{\nabla f(x_{j+1})^T \nabla f(x_k) - \nabla f(x_j)^T \nabla f(x_k)}{\nabla f(x_{j+1})^T d_j - \nabla f(x_j)^T d_j} d_j \end{aligned}$$

Mise à jour des directions

Du dernier lemme, $\nabla f(x_j)^T \nabla f(x_k) = 0$ et $\nabla f(x_k)^T d_j = 0$ si $j < k$, et donc

$$\begin{aligned} d_k &= -\nabla f(x_k) + \frac{\nabla f(x_k)^T \nabla f(x_k)}{-\nabla f(x_{k-1})^T d_{k-1}} d_{k-1} \\ &= -\nabla f(x_k) - \frac{\|\nabla f(x_k)\|^2}{\nabla f(x_{k-1})^T d_{k-1}} d_{k-1} \end{aligned}$$

Dès lors

$$d_{k-1}^T \nabla f(x_{k-1}) = -\|\nabla f(x_{k-1})\|^2$$

et

$$d_k = -\nabla f(x_k) + \frac{\|\nabla f(x_k)\|^2}{\|\nabla f(x_{k-1})\|^2} d_{k-1}$$

C'est la règle du **gradient conjugué** pour la mise à jour de la direction de recherche.

Considérations pratiques

- Dans le calcul de d_k , nous devons seulement garder deux vecteurs et un scalaire stockés dans la mémoire centrale: d_{k-1} , x_k et $\|\nabla f(x_{k-1})\|^2$.
- Les registres occupés par ces données sont réécrits durant le calcul du nouvel itéré par d_k , x_{k+1} et $\|\nabla f(x_k)\|^2$.
- La méthode se termine en au plus n itérations.
- De plus, en général, x_k donne une bonne approximation de x^* après quelques itérations, et les itérations restantes sont utilisées pour affiner le résultat.

Calcul de α_k

Nous avons obtenu

$$\alpha_k = -\frac{d_k^T \nabla f(x_k)}{d_k^T B d_k}$$

Or, pour $k > 1$,

$$d_k = -\nabla f(x_k) + \frac{\|\nabla f(x_k)\|^2}{\|\nabla f(x_{k-1})\|^2} d_{k-1}$$

et nous pouvons réécrire le calcul de α_k comme

$$\alpha_k = -\frac{(-\nabla f(x_k) + \frac{\|\nabla f(x_k)\|^2}{\|\nabla f(x_{k-1})\|^2} d_{k-1})^T \nabla f(x_k)}{d_k^T B d_k}$$

En utilisant la propriété $d_{k-1}^T \nabla f(x_k) = 0$, l'égalité devient

$$\alpha_k = \frac{\|\nabla f(x_k)\|_2^2}{d_k^T B d_k}$$

Algorithme: gradients conjugués

Étape 0. Soient $x_0 \in \mathcal{R}^n$, $d_0 := -\nabla f(x_0)$, $k := 0$.

Étape 1. Calculer

$$\alpha_k = \arg \min_{\alpha} f(x_k + \alpha d_k)$$

et poser

$$x_{k+1} = x_k + \alpha_k d_k.$$

Étape 2. Si $k < n - 1$, calculer

$$d_{k+1} = -\nabla f(x_{k+1}) + \frac{\|\nabla f(x_{k+1})\|^2}{\|\nabla f(x_k)\|^2} d_k$$

Poser $k := k + 1$. Si $k = n$, arrêt; $x^* = x_n$. Sinon, retourner à l'étape 1.

Remarque d'implémentation

On pourra remplacer

$$\frac{\|\nabla f(x_{k+1})\|^2}{\|\nabla f(x_k)\|^2}$$

par

$$\frac{\nabla f(x_{k+1})^T B d_k}{d_k^T B d_k}$$

En effet, comme $\nabla f(x_{k+1})^T \nabla f(x_k) = 0$, $d_k^T \nabla f(x_{k+1}) = 0$ et

$$B d_k = \frac{1}{\alpha_k} (\nabla f(x_{k+1}) - \nabla f(x_k)),$$

nous avons

$$\begin{aligned} \frac{\nabla f(x_{k+1})^T B d_k}{d_k^T B d_k} &= \frac{\nabla f(x_{k+1})^T (\nabla f(x_{k+1}) - \nabla f(x_k))}{d_k^T (\nabla f(x_{k+1}) - \nabla f(x_k))} \\ &= - \frac{\nabla f(x_{k+1})^T \nabla f(x_{k+1})}{d_k^T \nabla f(x_k)} \end{aligned}$$

Vitesse de convergence

Conn, Gould, Toint, théorème 5.1.7

Théorème

L'erreur résiduelle $\epsilon_k = x_k - x^$ des itérés générés par l'algorithme du gradient conjugué satisfait l'inégalité*

$$\frac{\|\epsilon_k\|_B}{\|\epsilon_0\|_B} \leq 2 \left(\frac{\sqrt{\kappa(B)} - 1}{\sqrt{\kappa(B)} + 1} \right)^k$$

où $\kappa(B)$ est le conditionnement de B .

Conditionnement

Le conditionnement d'une matrice normale B est le rapport entre les valeurs absolues de la plus grande et de la plus petite valeur propre:

$$\kappa(B) = \frac{|\lambda_{\max}(B)|}{|\lambda_{\min}(B)|}$$

Note: En algèbre linéaire, une matrice carrée A à coefficients complexes est une matrice normale si elle commute avec sa matrice adjointe A^* , c'est-à-dire si $AA^* = A^*A$. Si tous les coefficients sont réels, $A^* = A^T$, et toute matrice symétrique est normale.

Algorithme du gradient conjugué préconditionné

Idée: appliquer le gradient conjugué après un changement linéaire de coordonnées au moyen d'une matrice R inversible:

$$x = R^{-1}y.$$

Nous cherchons alors à résoudre

$$BR^{-1}y = -b,$$

ou, de manière équivalente, avec $c = -b$,

$$R^{-\top}BR^{-1}y = R^{-\top}c.$$

Si $B \succ 0$, $R^{-\top}BR^{-1} \succ 0$ vu que $\forall x \neq 0$,

$$x^{\top}R^{-\top}BR^{-1}x > 0.$$

Nous pouvons dès lors utiliser le gradient conjugué comme précédemment.

Algorithme du gradient conjugué préconditionné

Nous voudrions choisir R tel que $\kappa(R^{-\top}BR^{-1}) \approx 1$ afin d'accélérer la convergence, ce qui se fait cependant au coût additionnel de la multiplication par R^{-1} à chaque itération.

Cas extrême: $R = B$.

Notons

$$\overline{B} := R^{-\top}BR^{-1}, \quad \overline{c} = R^{-\top}c.$$

Ne voulons pas former explicitement $\overline{B}$ et $\overline{c}$ comme $\overline{B}$ pourrait être dense alors que B serait creuse. Nous souhaitons plutôt une méthode implicite.

Le but est de trouver R facile à inverser et qui approxime bien B , en regroupant les valeurs de propres de $R^{-1}B$.

Factorisation de Cholesky exacte

Si nous calculons la factorisation de Cholesky exacte

$$B = LL^{\top},$$

alors en choisissant $R = L^{\top}$, nous obtenons

$$R^{-\top}BR^{-1} = I,$$

et le gradient conjugué converge en une seule itération.

Factorisation de Cholesky exacte

La Cholesky exacte vérifie les relations

$$R_{ii} = \sqrt{B_{ii} - \sum_{k < i} R_{ki}^2},$$

$$R_{ij} = \frac{1}{R_{ii}} \left(B_{ij} - \sum_{k < i} R_{ki} R_{kj} \right), \quad j > i.$$

Ces formules introduisent naturellement du *remplissage*, et par conséquent cette factorisation est souvent trop coûteuse pour les matrices creuses de grande taille.

Factorisation de Cholesky incomplète

La factorisation de Cholesky incomplète consiste à construire une matrice triangulaire R telle que

$$B \approx R^{\top} R,$$

tout en imposant une structure de parcimonie prédéfinie.

Cholesky incomplète IC(0)

Soit

$$\mathcal{S} = \{(i,j) \mid B_{ij} \neq 0, i \leq j\}.$$

La factorisation **IC(0)** cherche une matrice triangulaire supérieure R vérifiant

$$R_{ij} = 0 \quad \text{si } (i,j) \notin \mathcal{S},$$

et telle que

$$R^\top R \approx B.$$

Autrement dit :

- la structure creuse de R est fixée *a priori*,
- aucun nouveau coefficient non nul (*fill-in*) n'est autorisé.

Modification IC(0)

Pour IC(0), on modifie la seconde relation comme suit :

$$R_{ij} = \begin{cases} \frac{1}{R_{ii}} \left(B_{ij} - \sum_{\substack{k < i \\ (k,i),(k,j) \in \mathcal{S}}} R_{ki} R_{kj} \right), & \text{si } (i,j) \in \mathcal{S}, \\ 0, & \text{si } (i,j) \notin \mathcal{S}. \end{cases}$$

Ainsi :

- les mises à jour hors du motif $\mathcal{S}$ sont simplement ignorées,
- aucun nouveau coefficient non nul n'est créé,
- la factorisation reste peu coûteuse.

Effet spectral du préconditionnement

Nous pouvons écrire

$$B = R^{\top} R + E,$$

où E est une matrice d'erreur symétrique.

Le préconditionneur est alors

$$M = R^{\top} R.$$

Le système préconditionné s'écrit

$$R^{-\top} B R^{-1} = I + R^{-\top} E R^{-1}.$$

Si E est de norme faible, les valeurs propres de la matrice préconditionnée sont regroupées autour de 1, ce qui entraîne une convergence rapide du gradient conjugué.

Définie-positivité et échec possible de la Cholesky incomplète

La factorisation de Cholesky exacte construit une factorisation

$$B = R^{\top} R,$$

pour laquelle tous les pivots intermédiaires sont strictement positifs :

$$B_{ii} - \sum_{k < i} R_{ki}^2 > 0, \quad i = 1, \dots, n.$$

les pivots calculés sont alors

$$R_{ii} = \sqrt{B_{ii} - \sum_{\substack{k < i \\ (k,i) \in \mathcal{S}}} R_{ki}^2},$$

où $\mathcal{S}$ désigne le motif de parcimonie imposé.

Même si B est symétrique définie positive, la factorisation de Cholesky incomplète (IC) peut cependant *échouer*, vu que

Définie-positivité et échec possible de la Cholesky incomplète

Il peut arriver que

$$B_{ii} - \sum_{\substack{k < i \\ (k,i) \in \mathcal{S}}} R_{ki}^2 \leq 0,$$

malgré la définie-positivité globale de B . Dans ce cas, la racine carrée n'est pas définie et la factorisation échoue.

Cet échec est dû au caractère *approché* de la factorisation et à la suppression de contributions nécessaires à la positivité des pivots intermédiaires.

Plusieurs stratégies existent face à ce problème. La plus simple est d'arrêter la factorisation si ce cas se produit.

Algorithme GC pour le problème transformé

Étant donné y_0 , poser $\bar{g}_0 = \bar{B}y_0 + \bar{c}$ et $\bar{d}_0 = -\bar{g}_0$. Pour $k = 0, 1, 2, \dots$, jusqu'à convergence, faire

$$\alpha_k = \frac{\|\bar{g}_k\|_2^2}{\bar{d}_k^\top \bar{B} \bar{d}_k}$$

$$y_{k+1} = y_k + \alpha_k \bar{d}_k$$

$$\bar{g}_{k+1} = \bar{g}_k + \alpha_k \bar{B} \bar{d}_k$$

$$\beta_k = \frac{\|\bar{g}_{k+1}\|_2^2}{\|\bar{g}_k\|_2^2}$$

$$\bar{d}_{k+1} = -\bar{g}_{k+1} + \beta_k \bar{d}_k$$

On va tâcher de revenir à un algorithme en termes de x .

Algorithme GC préconditionné

Posons $y_k = Rx_k$, $\bar{d}_k = Rd_k$, alors

$$y_{k+1} = y_k + \alpha_k \bar{d}_k$$

devient

$$Rx_{k+1} = Rx_k + \alpha_k Rd_k$$

et en prémultipliant par R^{-1}

$$x_{k+1} = x_k + \alpha_k d_k$$

Similairement, prenons $\bar{g}_k = R^{-\top} g_k$. Alors

$$\bar{g}_{k+1} = \bar{g}_k + \alpha_k \bar{B} \bar{d}_k$$

se réécrit

$$g_{k+1} = g_k + \alpha_k B d_k$$

Algorithme GC préconditionné

De même

$$\|\bar{g}_k\|_2^2 = \|R^{-\top} g_k\|_2^2 = \langle R^{-\top} g_k, R^{-\top} g_k \rangle = \langle g_k, R^{-1} R^{-\top} g_k \rangle$$

Finalement,

$$\bar{d}_{k+1} = -\bar{g}_{k+1} + \beta_k \bar{d}_k$$

devient

$$Rd_{k+1} = -R^{-\top} g_{k+1} + \beta_k Rd_k$$

ou

$$d_{k+1} = -R^{-1} R^{-\top} g_{k+1} + \beta_k d_k$$

Algorithme GC préconditionné

Les constantes deviennent quant à elles

$$\alpha_k = \frac{\langle g_k, R^{-1}R^{-\top}g_k \rangle}{\langle Rd_k, R^{-\top}BR^{-1}Rd_k \rangle} = \frac{\langle g_k, R^{-1}R^{-\top}g_k \rangle}{\langle d_k, Bd_k \rangle}$$

et

$$\beta_k = \frac{\langle g_{k+1}, R^{-1}R^{-\top}g_{k+1} \rangle}{\langle g_k, R^{-1}R^{-\top}g_k \rangle}$$

En définissant

$$M = R^{\top}R$$

et

$$v_k = M^{-1}g_k$$

nous obtenons l'algorithme suivant

Algorithme GC préconditionné

Étant donné x_0 , posons $g_0 = Bx_0 + c$. Soit $v_0 = M^{-1}g_0$ et $d_0 = -v_0$. Pour $k = 0, 1, 2, \dots$, jusqu'à convergence, faire

$$\alpha_k = \frac{\langle g_k, v_k \rangle}{d_k^T B d_k}$$

$$x_{k+1} = x_k + \alpha_k d_k$$

$$g_{k+1} = g_k + \alpha_k B d_k$$

$$v_{k+1} = M^{-1}g_{k+1}$$

$$\beta_k = \frac{\langle g_{k+1}, v_{k+1} \rangle}{\langle g_k, v_k \rangle}$$

$$d_{k+1} = -v_{k+1} + \beta_k d_k$$

M est appelé preconditionneur.

Vitesse de convergence

Notons tout d'abord que les valeurs propres de $M^{-1}B$ sont les mêmes que celles de $R^{-\top}BR^{-1}$. En effet, si λ est valeur propre de $M^{-1}B$, il existe un u tel que

$$M^{-1}Bu = \lambda u$$

et nous pouvons écrire

$$R^{-1}R^{-\top}Bu = \lambda u$$

ou

$$R^{-\top}Bu = \lambda Ru$$

Soit $\nu := Ru$. Nous obtenons

$$R^{-\top}BR^{-1}\nu = \lambda\nu$$

Vitesse de convergence

Théorème

L'erreur résiduelle $\epsilon_k = x_k - x^$ des itérés générés par l'algorithme du gradient conjugué préconditionné satisfait l'inégalité*

$$\frac{\|\epsilon_k\|_B}{\|\epsilon_0\|_B} \leq 2 \left(\frac{\sqrt{\kappa(M^{-1}B)} - 1}{\sqrt{\kappa(M^{-1}B)} + 1} \right)^k$$

où $\kappa(M^{-1}B)$ est le conditionnement de $M^{-1}B$.

Corollaire

Si $M^{-1}B$ a ℓ valeurs propres distinctes, l'algorithme du gradient conjugué préconditionné se terminera avec $x_j = x^$ pour un certain $j \leq \ell$.*

Produit matrice hessienne et vecteur

Il est à noter dans l'algorithme qu'il n'est jamais nécessaire de connaître B explicitement, seul son "effet" est important, i.e. étant donné un vecteur y , nous devons pouvoir calculer Bv . Remarquons que

$$\begin{aligned}\nabla_x(\nabla_x f(x)^\top v) &= \nabla_x \left(\sum_{i=1}^n \frac{df(x)}{dx_i} v_i \right) \\ &= \sum_{i=1}^n \nabla_x \frac{df(x)}{dx_i} v_i \\ &= \sum_{i=1}^n \begin{pmatrix} \frac{d^2 f(x)}{dx_i dx_1} \\ \frac{d^2 f(x)}{dx_i dx_2} \\ \vdots \\ \frac{d^2 f(x)}{dx_i dx_n} \end{pmatrix} v_i \\ &= Bv.\end{aligned}$$

Produit matrice hessienne et vecteur

Autrement dit, il n'est pas nécessaire de stocker B , mais alors il faut être capable d'évaluer le gradient du produit scalaire entre $\nabla_x f(x)$ et v , et ce pour tout nouvel itéré x .

Dans certains cas, on pourra formuler analytiquement ce produit, sinon on utilisera les approches de différentiation automatique.

Méthode de Fletcher-Reeves

Cet algorithme peut être adapté pour la minimisation d'une fonction arbitraire $f \in C^1$ est alors appelé méthode de Fletcher-Reeves. Les différences principales sont les suivantes:

- les recherches linéaires exactes doivent être remplacées par des recherches linéaires pratiques;
- un critère d'arrêt $\|\nabla f(x_k)\| < \epsilon$ doit être utilisé pour garantir que l'algorithme se termine en temps fini;
- puisque le second lemme est seulement établi pour des fonctions quadratiques convexes, le caractère conjugué de d_k ne peut être que réalisé approximativement et il convient de réinitialiser d_k à $-\nabla f(x_k)$ périodiquement.

Algorithme de Fletcher-Reeves

Étape 0. Choisir x_0 et poser $d_0 = -\nabla f(x_0)$ Poser $k = 0$.

Étape 1. Poser

$$x_{k+1} = x_k + \alpha_k d_k$$

où

$$\alpha_k = \arg \min_{\alpha} f(x_k + \alpha d_k)$$

Étape 2. Arrêt si $\|\nabla f(x_{k+1})\| < \epsilon$.

Étape 3. Calculer

$$d_{k+1} = -\nabla f(x_{k+1}) + \beta_{k+1} d_k$$

où

$$\beta_{k+1} = \frac{\|\nabla f(x_{k+1})\|^2}{\|\nabla f(x_k)\|^2}$$

Incrémenter k de 1. Retour à l'étape 1.