

IFT 3515
Fonctions à plusieurs variables
Optimisation sous contraintes
Méthodes de projection

Fabian Bastin
DIRO
Université de Montréal

Cadre de travail

Jusqu'à présent, nous n'avons considéré que des problèmes d'optimisation sans contraintes. La plupart des problèmes pratiques présentent toutefois des contraintes, et il convient d'adapter nos méthodes pour en tenir compte.

Nous considérons dans un premier temps des contraintes simples, définissant une région convexe.

Soit le programme

$$\min_{x \in \mathcal{X}} f(x)$$

où $\mathcal{X} \subseteq \mathbb{R}^n$ est l'ensemble réalisable, supposé fermé et non vide.

Ensemble convexe

De plus, nous supposons pour le moment que $\mathcal{X}$ est convexe, et qu'il est relativement aisé de projeter n'importe quel point sur cet ensemble.

Rappel : un ensemble $\mathcal{X}$ est convexe ssi toute combinaison convexe de points dans $\mathcal{X}$ est également dans $\mathcal{X}$:

$$\forall x, y \in \mathcal{X}, \forall \lambda \in [0, 1], \lambda x + (1 - \lambda)y \in \mathcal{X}.$$

Conditions d'optimalité au premier ordre

Lecture suggérée : Nocedal et Wright, Chapitre 12.

Nous devons tout d'abord revoir nos conditions d'optimalité pour le cas contraint.

Théorème (Condition nécessaire au premier ordre)

Soit f continûment différentiable sur $\mathcal{X} \in \mathbb{R}^n$, avec $\mathcal{X}$ fermé et non vide. Si x^ est un minimum local de f , alors*

$$-\nabla_x f(x^*) \in \mathcal{N}_{\mathcal{X}}(x^*),$$

où $\mathcal{N}_{\mathcal{X}}(x^)$ est le cône normal à $\mathcal{X}$ en x^* .*

Si f est convexe, la condition est nécessaire et suffisante.

Définitions

Définition (Cône)

Un sous-ensemble $\mathcal{C}$ d'un espace vectoriel V est un **cône** linéaire ssi αx appartient à $\mathcal{C}$ pour tout $x \in \mathcal{C}$ et tout scalaire $\alpha > 0$.

Le cône est pointé si $\forall \alpha \geq 0, \alpha x \in \mathcal{C}$.

Définition (Cône convexe)

Un **cône convexe** $\mathcal{C}$ est un cône fermé sous les combinaisons convexes, i.e. ssi $\alpha x + \beta y \in \mathcal{C}, \forall \alpha, \beta > 0$, avec $\alpha + \beta = 1$.

Cône tangent et cône normal

Définition (Vecteur tangent)

Un vecteur $w \in \mathbb{R}^n$ est tangent à $\mathcal{X}$ en $x \in \mathcal{X}$ si pour toute séquence de vecteurs $\{x_i\}$ avec $x_i \rightarrow x$ et $x_i \in \mathcal{X}$, et toute séquence de scalaires positifs $t_i \downarrow 0$, il existe une séquence $w_i \rightarrow w$ telle que $x_i + t_i w_i \in \mathcal{X}$ pour tout i .

Définition (Cône tangent)

Le **cône tangent** $T_{\mathcal{X}}(x)$ est la collection des vecteurs tangents à $\mathcal{X}$ en x .

Définition (Cône normal)

Le **cône normal** $N_{\mathcal{X}}(x)$ est le complément orthogonal de $T_{\mathcal{X}}(x)$, i.e.

$$N_{\mathcal{X}}(x) = \{v \mid v^T w \leq 0, \forall w \in T_{\mathcal{X}}(x)\}.$$

Cas convexe : cône normal

La définition de cône normal peut être simplifiée si $\mathcal{X}$ est convexe. Nous avons en effet alors

$$N_{\mathcal{X}}(x) = \begin{cases} \{v \mid v^T(y - x) \leq 0, \forall y \in \mathcal{X}\} & \text{si } x \in \mathcal{X}, \\ \emptyset & \text{sinon.} \end{cases}$$

La condition nécessaire d'optimalité devient alors

$$\nabla f(x^*)^T(y - x^*) \geq 0 \quad \forall y \in \mathcal{X}$$

Si f est convexe (i.e. nous sommes dans le cadre de la programmation convexe), la condition est aussi suffisante.

Cas convexe : cône tangent

Dans le cas convexe, le cône tangent en $x \in \mathcal{X}$ devient

$$T_{\mathcal{X}}(x) = cl\{\theta(x_0 - x) \mid \theta \geq 0 \text{ et } x_0 \in \mathcal{X}\},$$

où $cl\{\mathcal{S}\}$ désigne la fermeture (closure) de l'ensemble $\mathcal{S}$:

$$cl\{\mathcal{S}\} = \{x \mid \forall \epsilon > 0, \mathcal{S} \cap \mathcal{B}(x, \epsilon) \neq \emptyset\}.$$

Décomposition de Moreau avec $y \in \mathcal{X}$:

$$x = P_{T_{\mathcal{X}}(y)}(x) + P_{\mathcal{N}_{\mathcal{X}}(y)}(x).$$

Cône tangent : interprétation

Intuition. Depuis un point $x \in \mathcal{X}$, le cône tangent $T_{\mathcal{X}}(x)$ rassemble toutes les directions dans lesquelles on peut « partir » de x en restant dans $\mathcal{X}$, au moins pour un petit pas.


Rappelons que d est une **direction réalisable** en $x \in \mathcal{X}$ s'il existe $\alpha_{\max} > 0$ tel que $x + \alpha d \in \mathcal{X}$ pour tout $\alpha \in [0, \alpha_{\max}]$. Toute direction réalisable appartient à $T_{\mathcal{X}}(x)$.

Le cône tangent est la **fermeture** du cône des directions réalisables : il inclut en plus les directions limites, obtenues comme limites de directions réalisables. Cela est nécessaire lorsque x est un point frontière de $\mathcal{X}$ où la marge de manœuvre tend vers zéro.

Cas particuliers :

- Si $x \in \text{int}(\mathcal{X})$, alors $T_{\mathcal{X}}(x) = \mathbb{R}^n$: toutes les directions sont réalisables.
- Si x est sur la frontière de $\mathcal{X}$, le cône tangent est un demi-espace ou un cône plus restrictif, selon la géométrie locale de $\mathcal{X}$ en x .

Illustration graphique



Gauche : x au sommet de Ω — $T_{\Omega}(x)$ est le cône des directions réalisables depuis x , $N_{\Omega}(x)$ est le cône des directions opposées. Droite : x sur la frontière courbe de Ω — $T_{\Omega}(x)$ est le demi-espace délimité par la tangente en x , $N_{\Omega}(x)$ est la demi-droite normale extérieure.

Théorème de projection

Étant donné $x_0 \in \mathbb{R}^n$, nous voudrions identifier le point le plus proche de x_0 appartenant à $\mathcal{X}$. Le théorème suivant caractérise ce point.

Théorème (Projection pour des ensembles convexes)

Soit $x_0 \in \mathbb{R}^n$ et $\mathcal{X} \subseteq \mathbb{R}^n$ un ensemble convexe, fermé et non vide. $\bar{x} \in \mathcal{X}$ résoud le problème

$$\min_{x \in \mathcal{X}} \frac{1}{2} \|x - x_0\|_2^2$$

si et seulement si $\forall y \in \mathcal{X}$,

$$\langle \bar{x} - x_0, y - \bar{x} \rangle \geq 0.$$

De plus, la solution $\bar{x}$ existe toujours, et est unique.

Preuve

Soit

$$f(x) = \frac{1}{2} \|x - x_0\|_2^2$$

L'existence d'un minimum de $f(x)$ vient de la compacité de l'ensemble

$$\{x \in \mathcal{X} \mid \|x - x_0\|_2 \leq \|\hat{x} - x_0\|_2\}$$

pour n'importe quel $\hat{x} \in \mathcal{X}$.

D'autre part, f est strictement convexe, et donc admet un minimum unique, qui s'obtient en appliquant les conditions d'optimalité au premier ordre, ou

$$\nabla f(x) = x - x_0.$$

Projection

Définition (Projection)

Soit $\mathcal{X} \subseteq \mathbb{R}^n$ un ensemble convexe, fermé et non vide. La projection $P_{\mathcal{X}}$ est le mapping $P_{\mathcal{X}} : \mathbb{R}^n \rightarrow \mathcal{X}$ donné par

$$\|P_{\mathcal{X}} - x\|_2^2 = \min_y \{\|y - x\|_2^2 \mid y \in \mathcal{X}\}$$

Contraintes de bornes

Un des cas les plus simples est la situation où les variables de décision sont bornées inférieurement et supérieurement.

$$\mathcal{X} = \{x \mid x_\ell \leq x \leq x_u\}$$

où les inégalités sont à comprendre composante par composante.

Nous autorisons certaines composantes de x_ℓ à être égale à $-\infty$ et certaines composantes de x_u à être égale à $+\infty$.

Soit $y \in \mathbb{R}^n$. La projection de y sur $\mathcal{X}$ est extrêmement facile à obtenir :

$$[P_{\mathcal{X}}(y)]_i = \begin{cases} [x_\ell]_i & \text{si } [y]_i \leq [x_\ell]_i \\ [y]_i & \text{si } [x_\ell]_i \leq [y]_i \leq [x_u]_i \\ [x_u]_i & \text{si } [y]_i \geq [x_u]_i \end{cases}$$

où $[\cdot]_i$ représente la i^e composante.

Autres domaines simples

Il existe d'autres domaines sur lesquels projeter est relativement simple.

Par exemple, les projections sur une sphère sont triviales. Soit

$$\mathcal{X} = \{x \in \mathbb{R}^n \mid \|x - x_0\|_2 \leq \delta\}.$$

La projection est donnée par

$$P_{\mathcal{X}}(y) = \begin{cases} y & \text{if } y \in \mathcal{X}, \\ x_0 + \delta \frac{y - x_0}{\|y - x_0\|_2} & \text{otherwise.} \end{cases}$$

Chemin du gradient projeté

De ce qui précède, un point x^* est un point critique au premier ordre si $-\nabla f(x^*) \in N_{\mathcal{X}}(x^*)$.

Considérons les points de long de l'arc de Cauchy à partir de x :

$$\{x - t\nabla f(x) \mid t \geq 0\}$$

et définissons le chemin du gradient projeté :


$$p(t, x) := P_{\mathcal{X}}(x - t\nabla f(x)), \quad \forall t \geq 0.$$

Si $\mathcal{X}$ est convexe et x^* est critique au premier ordre, alors $\forall t \geq 0$

$$\nabla f(x^*)^T (x^* - P_{\mathcal{X}}(x^* - t\nabla f(x^*))) \leq 0.$$

Si $P_{\mathcal{X}}(x^* - t\nabla f(x^*)) = x^*$, l'inégalité est trivialement satisfaite. Est-ce à dire que tout point critique au premier ordre satisfait cette dernière égalité ?

Chemin du gradient projeté : illustration



Optimalité et projection

Théorème (Projections et cône normal)

Soit $\mathcal{X}$ un sous-ensemble fermé convexe et non-vide de $\mathbb{R}^n$ et soit $P_{\mathcal{X}}$ l'opérateur de projection sur $\mathcal{X}$. Alors, pour $x \in \mathbb{R}^n$, nous avons $z = P_{\mathcal{X}}(x)$ si et seulement si

$$(x - z) \in N_{\mathcal{X}}(z)$$

Optimalité et projection

Démonstration.

En vertu du théorème de projection, pour tout $y \in \mathcal{X}$,

$$\langle P_{\mathcal{X}}(x) - x, y - P_{\mathcal{X}}(x) \rangle \geq 0.$$

$\Rightarrow$ Si $z = P_{\mathcal{X}}(x)$, $x - z = x - P_{\mathcal{X}}(x)$, et dès lors

$$\langle x - z, z - y \rangle \geq 0, \quad \forall y \in \mathcal{X}.$$

Par définition de $N_{\mathcal{X}}(z)$, $(x - z) \in N_{\mathcal{X}}(z)$.

$\Leftarrow$ Supposons maintenant $(x - z) \in N_{\mathcal{X}}(z)$, ou de manière équivalente

$$\langle x - z, z - y \rangle \geq 0, \quad \forall y \in \mathcal{X}.$$

En vertu du théorème de projection, $z = P_{\mathcal{X}}(x)$.

Optimalité et projection

Corollaire

Soit $x \in \mathcal{X}$, $z \in N_{\mathcal{X}}(x)$ et $t \geq 0$. Alors, $P_{\mathcal{X}}(x + tz) = x$.

Démonstration.

Du théorème de projection, $P_{\mathcal{X}}(x + tz)$ est l'unique point t.q. $\forall y \in \mathcal{X}$,

$$\langle x + tz - P_{\mathcal{X}}(x + tz), P_{\mathcal{X}}(x + tz) - y \rangle \geq 0.$$

Dès lors, $P_{\mathcal{X}}(x + tz) = x$ ssi $\forall y \in \mathcal{X}$,

$$\langle x + tz - x, x - y \rangle \geq 0.$$

ou

$$\langle tz, x - y \rangle \geq 0.$$

Cette dernière inégalité est satisfaite comme $tz \in N_{\mathcal{X}}(x)$.

Optimalité et projection

Corollaire

x^* est solution de

$$\min_{x \in \mathcal{X}} f(x)$$

ssi pour tout $t \geq 0$,

$$P_{\mathcal{X}}(x^* - t \nabla f(x^*)) = x^*.$$

Optimalité et projection

Démonstration.

Supposons tout d'abord que x^* est solution. Des conditions d'optimalité au premier ordre,

$$-\nabla f(x^*) \in N_{\mathcal{X}}(x^*)$$

Il suffit alors d'appliquer le théorème précédent.

D'autre part, si $\forall t \geq 0$,

$$P_{\mathcal{X}}(x^* - t\nabla f(x^*)) = x^*$$

alors

$$x^* - t\nabla f(x^*) - P_{\mathcal{X}}(x^* - t\nabla f(x^*)) = -t\nabla f(x^*) \in N_{\mathcal{X}}(x^*)$$

.



Gradient projeté et descente

Théorème

Soit $x \in \mathcal{X}$ et $d = P_{\mathcal{X}}(x - t\nabla f(x)) - x$. d est une direction de descente.

Le résultat tient en particulier pour $t = 1$.

Gradient projeté et descente

Démonstration.

Le résultat suit de l'observation

$$\nabla f(x)^T d \leq -\frac{\|P_{\mathcal{X}}(x - t\nabla f(x)) - x\|_2^2}{t}$$

En effet,

$$\begin{aligned} & \|P_{\mathcal{X}}(x - t\nabla f(x)) - x\|_2^2 \\ &= \langle P_{\mathcal{X}}(x - t\nabla f(x)) - x, P_{\mathcal{X}}(x - t\nabla f(x)) - x \rangle \\ &= \langle P_{\mathcal{X}}(x - t\nabla f(x)) - x, d \rangle + t\nabla f(x)^T d - t\nabla f(x)^T d \\ &= -t\nabla f(x)^T d + \langle P_{\mathcal{X}}(x - t\nabla f(x)) - (x - t\nabla f(x)), d \rangle \\ &\leq -t\nabla f(x)^T d \end{aligned}$$

où la dernière inégalité résulte en vertu du théorème de projection, comme $x \in \mathcal{X}$.

Algorithme basique du gradient projeté

Comme d est une direction de descente, nous pouvons construire un algorithme de recherche linéaire l'exploitant.

Étape 0. Soit $x_0 \in \mathcal{X}$, et $k = 0$.

Étape 1. Calculer

$$d_k = P_{\mathcal{X}}(x_k - \nabla f(x_k)) - x_k.$$

Étape 2. Résoudre approximativement

$$\min_{\alpha \geq 0} f(x_k + \alpha d_k)$$

en satisfaisant la condition d'Armijo.

Étape 3. Poser

$$x_{k+1} = x_k + \alpha_k d_k.$$

Arrêt si un critère de convergence est satisfait. Sinon, retour à l'Étape 1.

Convergence

Soit $f : \mathbb{R}^n \rightarrow \mathbb{R} \in C^1$, et soit $\mathcal{X} \subseteq \mathbb{R}^n$ non-vide, fermé et convexe. Supposons aussi que $\nabla f(x)$ est lipschitzienne sur $\mathbb{R}^n$. Alors, pour les itérés générés par la méthode de recherche linéaire avec pas d'Armijo, une des trois situations suivantes a lieu :

1. il existe un k_0 tel que $-\nabla f(x_{k_0}) \in N_{\mathcal{X}}(x_{k_0})$.
2. $\lim_{k \rightarrow \infty} f(x_k) = -\infty$
3. Il existe une sous-séquence $\{x_{k_j}\} \subseteq \{x_k\}$ telle que

$$\lim_{j \rightarrow \infty} \|P_{\mathcal{X}}(x_{k_j} - \nabla f(x_{k_j})) - x_{k_j}\| = 0.$$

Chemin du gradient projeté

Un inconvénient de l'approche précédente est que si

$d_k = P_{\mathcal{X}}(x_k - \nabla f(x_k)) - x_k \neq -\nabla f(x_k)$, même pour une faible longueur de pas, la direction de descente ne correspondra jamais à la plus forte pente.

Nous pouvons décider de suivre la plus forte pente jusqu'à rendre une contrainte active, et alors seulement projeter le pas.

Pour se faire, nous devons modifier l'étape 2 en calculant

$$\min_{\alpha \geq 0} f(P_{\mathcal{X}}(x_k + \alpha d_k)).$$

La fonction

$$\phi(\alpha) = f(P_{\mathcal{X}}(x_k + \alpha d_k))$$

n'est cependant plus linéaire en α et est seulement différentiable par morceaux.

Chemin du gradient projeté

La longueur du pas devra être sélectionnée pour produire une décroissance suffisante de la valeur de la fonction objectif, mais nous devons être vigilant avec la formule d'Armijo :

$$f(x_k + \alpha_k d_k) \leq f(x_k) + \alpha_k \beta \nabla f(x_k)^T d_k$$

En effet, la recherche ne se fait pas le long de $x_k + \alpha d_k$, avec $d_k = P_{\mathcal{X}}(x_k - \nabla f(x_k)) - x_k \neq -\nabla f(x_k)$, et nous devons modifier le critère comme

$$f(x_k + s_k) \leq f(x_k) + \beta \nabla f(x_k)^T s_k$$

avec

$$s_k = P_{\mathcal{X}}(x_k + \alpha d_k) - x_k.$$

La condition est alors appelée **condition de Goldstein**.

Approche par région de confiance

L'algorithme de région de confiance peut aussi être adaptée en considérant en ajoutant au sous-problème à résoudre les contraintes du problème :

$$\begin{aligned} \min_s \quad & m_k(x_k + s) \\ \text{t.q.} \quad & \|s_k\|_k \leq \Delta_k \\ & x_k + s \in \mathcal{X}, \end{aligned}$$

où m_k est le sous-problème à résoudre, habituellement sous forme quadratique

$$m_k(x_k + s) = f(x_k) + \nabla f(x_k)^T s + \frac{1}{2} s^T B_k s.$$

Plus de détails peuvent être trouvés dans le chapitre 12 de “Trust-Region Methods”.

Point de Cauchy généralisé

Nous allons étendre la recherche linéaire de Goldstein pour tenir compte de la contrainte de région de confiance.

Définissons

$$s_k(t) \stackrel{\text{def}}{=} p(t, x_k) - x_k.$$

et simplifions la définition du modèle quadratique comme

$$m_k(s) = \nabla f(x_k)^T s + \frac{1}{2} s^T B_k s.$$

Notre but est de déterminer un $t_j > 0$ tel que les deux conditions suivantes soient satisfaites

$$\begin{aligned} \|s_k(t_j)\|_2 &\leq \Delta_k \\ m_k(p(t_j, x_k)) &\leq \beta_1 \nabla f(x_k)^T s_k(t_j), \end{aligned}$$

et au moins une des conditions

Point de Cauchy généralisé

$$\begin{aligned}\|s_k(t_j)\|_2 &\geq \mu \Delta_k \\ m_k(p(t_j, x_k)) &\geq \beta_2 \nabla f(x_k)^T s_k(t_j), \\ \left\| P_{T(p(t_j, x_k))}(-\nabla f(x_k)) \right\|_2 &\leq \nu \frac{|\nabla f(x_k)^T s_k(t_j)|}{\Delta_k},\end{aligned}$$

avec $0 < \beta_1 < \beta_2 < 1$, $\mu \in (0, 1)$, et $\nu \in (0, \frac{1}{2})$.

Le point

$$x_k^{\text{GC}} = p(t_j, x_k)$$

est le **point de Cauchy généralisé** (approximatif).

Calcul du point de Cauchy généralisé

- Étape 0** Soient $\Delta_k, x_k \in \mathcal{X}$, $m_k(x_k + s)$, $0 < \beta_1 < \beta_2 < 1$, $\mu \in (0, 1)$ et $\nu \in (0, \frac{1}{2})$. Poser $t_0 = \Delta_k / \|\nabla f(x_k)\|$, et $j = 0$.
- Étape 1** Calculer $m_k(p(t_j, x_k))$.
- Étape 2** Si $\|s_k(t_j)\| > \Delta_k$ ou $m_k(p(t_j, x_k)) > \beta_1 \nabla f(x_k)^T s_k(t_j)$, poser $t_{\max} = t_j$ et aller à l'étape 3.
Si $\|s_k(t_j)\|_2 < \mu \Delta_k$, $m_k(p(t_j, x_k)) < \beta_2 \nabla f(x_k)^T s_k(t_j)$ et $\left\| P_{T(p(t_j, x_k))}(-\nabla f(x_k)) \right\|_2 > \nu \frac{|\nabla f(x_k)^T s_k(t_j)|}{\Delta_k}$, poser $t_{\min} = t_j$ et aller à l'étape 3. Sinon retourner $x_k^{GC} = p(t_j, x_k)$.
- Étape 3** Si $t_{\max} = +\infty$, poser $t_{j+1} = 2t_j$. Sinon, poser $t_{j+1} = (t_{\min} + t_{\max})/2$. Incrémenter j de 1 et retourner à l'étape 1.

Calcul du point de Cauchy généralisé

t_0 est choisi à la longueur de pas maximale dans le cas où le chemin du gradient projeté se réduit à la direction de plus forte pente à l'intérieur de la région de confiance.

Sous certaines hypothèses de régularité, tout point d'accumulation d'accumulation génération par l'algorithme de région de confiance avec le point de Cauchy généralisé est un point critique au premier ordre.

L'algorithme suppose que la projection sur le cône tangent est facile à obtenir. Si $\mathcal{X}$ est simple, par exemple délimité par des contraintes de bornes, c'est le cas. D'autres situations sont plus complexes.

Projection sur le cône tangent : contraintes de bornes

Considérons à nouveau l'ensemble

$$\mathcal{X} = \{x \mid x_\ell \leq x \leq x_u\}$$

Nous avons

$$[P_{T_{\mathcal{X}}(x)}(d)]_i = \begin{cases} [d]_i & \text{si } [x_\ell]_i < [x]_i < [x_u]_i, \\ \max\{0, [d]_i\} & \text{si } [x]_i = [x_\ell]_i, \\ \min\{0, [d]_i\} & \text{si } [x]_i = [x_u]_i. \end{cases}$$

Contraintes actives - gradient conjugué

Il est possible d'étendre les techniques de projection à l'algorithme de gradient conjugué.

Question principale : si un itéré du gradient conjugué rend une contrainte active, comment procéder pour générer les directions de recherche ultérieures ?

Il va falloir à nouveau projeter les directions de recherche, et non seulement les itérés.

Méthode du gradient conjugué projeté

Il est possible d'adapter l'algorithme du gradient conjugué tronqué pour tenir compte de contraintes, comme expliqué dans Lin et Moré, *Newton's method for large bound-constrained optimization problems*, SIAM Journal on Optimization, 9(1999), 1100-1127.

Nous supposons que $\mathcal{X} \subseteq \mathbb{R}^n$ est un ensemble **convexe, fermé et non vide**, sur lequel il est aisé de projeter.

Idée de base : appliquer le gradient conjugué tronqué dans l'espace tangent à $\mathcal{X}$ en x_k^{GC} , en arrêtant les itérations dès qu'une contrainte est sur le point d'être violée ou que la région de confiance est atteinte.

Voir aussi Algorithme 16.2 de Nocedal et Wright.

Gradient réduit et espace tangent

Le **gradient projeté** en $x \in \mathcal{X}$ est la projection du gradient négatif sur le cône tangent :

$$\tilde{g}(x) = P_{T_{\mathcal{X}}(x)}(-\nabla f(x)).$$

C'est la direction de plus forte descente réalisable depuis x .

On note $Z(x) \in \mathbb{R}^{n \times p}$ une base orthonormale du sous-espace tangent actif en x ($p \leq n$). Le **gradient réduit** et la **hessienne réduite** sont alors

$$g^Z = Z(x)^T \nabla f(x) \in \mathbb{R}^p, \quad B^Z = Z(x)^T B Z(x) \in \mathbb{R}^{p \times p}.$$

Le GC tronqué cherche $s^Z \in \mathbb{R}^p$ solution approchée du système réduit

$$B^Z s^Z = -g^Z,$$

et reconstruit le pas complet $s = Z(x) s^Z$.

Idée générale de l'algorithme

À chaque itération extérieure k , à partir du point de Cauchy généralisé x_k^{GC} :

1. Déterminer le sous-espace tangent actif en x_k^{GC} et construire Z_k .
2. Calculer le gradient réduit $g_k^Z = Z_k^T \nabla f(x_k^{GC})$ et la hessienne réduite $B_k^Z = Z_k^T B_k Z_k$.
3. Appliquer le **GC tronqué** dans $\mathbb{R}^{p_k}$ pour résoudre $B_k^Z s^Z \approx -g_k^Z$, en tronquant dès que la région de confiance ou une contrainte est atteinte.
4. Reconstruire le pas complet $s_k = Z_k s^Z$ et poser $x_{k+1} = x_k + s_k$.

Les contraintes actives en x_k^{GC} sont **maintenues actives** durant les itérations du GC.

Cas des contraintes de bornes

Pour $\mathcal{X} = \{x \mid x_\ell \leq x \leq x_u\}$, le cône tangent en $x \in \mathcal{X}$ est diagonal :

$$[P_{T_{\mathcal{X}}(x)}(d)]_i = \begin{cases} [d]_i & \text{si } i \notin \mathcal{A}(x), \\ \max\{0, [d]_i\} & \text{si } [x]_i = [x_\ell]_i, \\ \min\{0, [d]_i\} & \text{si } [x]_i = [x_u]_i. \end{cases}$$

L'ensemble actif est $\mathcal{A}(x_k) = \{i \mid [x_k]_i = [x_\ell]_i\} \cup \{i \mid [x_k]_i = [x_u]_i\}$, et Z_k est formée des vecteurs canoniques e_i pour $i \notin \mathcal{A}(x_k^{GC})$.

Cas des contraintes de bornes : gradient réduit


Le gradient réduit revient à **annuler les composantes actives qui pointent hors de $\mathcal{X}$** :

$$[\tilde{g}_k]_i = \begin{cases} 0 & \text{si } [x_k^{GC}]_i = [x_\ell]_i \text{ et } [\nabla f(x_k)]_i < 0, \\ 0 & \text{si } [x_k^{GC}]_i = [x_u]_i \text{ et } [\nabla f(x_k)]_i > 0, \\ [\nabla f(x_k)]_i & \text{sinon.} \end{cases}$$

À la borne inférieure, seule une composante négative (faisant sortir x de $\mathcal{X}$) est bloquée ; les directions vers l'intérieur de $\mathcal{X}$ restent inchangées, et symétriquement à la borne supérieure.


Ceci est cohérent avec la projection sur le cône tangent : $\max\{0, [d]_i\}$ laisse passer les directions positives (vers l'intérieur) à la borne inférieure, et $\min\{0, [d]_i\}$ laisse passer les directions négatives à la borne supérieure.

Illustration : gradient réduit avec contraintes de bornes



bloquée

$[x]_2 = [x_\ell]_2, [\nabla f(x)]_2 < 0 : \text{bloquée}$
 $[\nabla f(x)]_1 > 0 : \text{libre}$



$[x]_1 = [x_u]_1, [\nabla f(x)]_1 > 0 : \text{bloquée}$
 $[x]_2 = [x_\ell]_2, [\nabla f(x)]_2 > 0 : \text{libre}$

Critères d'arrêt du GC dans l'espace réduit

Les itérations du GC dans l'espace réduit sont arrêtées dès que l'une des conditions suivantes est satisfaite :

1. **Région de confiance atteinte** : $\|s_k\|_k \geq \Delta_k$.
2. **Contrainte activée** : le pas prédit sortirait de $\mathcal{X}$, i.e. $x_k^{GC} + Z_k(s_j^Z + \alpha_j d_j) \notin \mathcal{X}$.
3. **Courbure négative ou nulle** : $d_j^T B_k^Z d_j \leq 0$ — le modèle quadratique n'est pas convexe dans cette direction.
4. **Convergence du résidu** : $\|r_j\| \leq \epsilon_k \|g_k^Z\|$ pour un seuil $\epsilon_k \in (0, 1)$ donné.

Dans les cas 1, 2 et 3, le pas est **tronqué** : on cherche le plus grand $\alpha^* \in [0, \alpha_j]$ tel que

$$\|s_j^Z + \alpha^* d_j\|_k \leq \Delta_k \quad \text{et} \quad x_k^{GC} + Z_k(s_j^Z + \alpha^* d_j) \in \mathcal{X}.$$

Algorithme du gradient conjugué projeté tronqué

Étape 0. Calculer x_k^{GC} , poser $s_0^Z = 0$, $r_0 = g_k^Z$, $d_0 = -r_0$, $j = 0$.

Étape 1. Si $\|r_j\| \leq \epsilon_k \|g_k^Z\|$, arrêt : $s^Z \leftarrow s_j^Z$.

Étape 2. Calculer $\kappa_j = d_j^T B_k^Z d_j$.

Si $\kappa_j \leq 0$: calculer α^* comme le plus grand $\alpha \geq 0$ tel que $\|s_j^Z + \alpha d_j\|_k \leq \Delta_k$ et $x_k^{GC} + Z_k(s_j^Z + \alpha d_j) \in \mathcal{X}$; poser $s^Z \leftarrow s_j^Z + \alpha^* d_j$ et arrêt.

Étape 3. Calculer $\alpha_j = r_j^T r_j / \kappa_j$.

Étape 4. Si $\|s_j^Z + \alpha_j d_j\|_k > \Delta_k$ ou $x_k^{GC} + Z_k(s_j^Z + \alpha_j d_j) \notin \mathcal{X}$:
calculer $\alpha^* = \max\{\alpha \in [0, \alpha_j] \mid \|s_j^Z + \alpha d_j\|_k \leq \Delta_k, x_k^{GC} + Z_k(s_j^Z + \alpha d_j) \in \mathcal{X}\}$;
poser $s^Z \leftarrow s_j^Z + \alpha^* d_j$ et arrêt.

Étape 5. Mettre à jour : $s_{j+1}^Z = s_j^Z + \alpha_j d_j$, $r_{j+1} = r_j + \alpha_j B_k^Z d_j$.

Étape 6. Calculer $\beta_j = r_{j+1}^T r_{j+1} / r_j^T r_j$, poser $d_{j+1} = -r_{j+1} + \beta_j d_j$.

Incrémenter j et retourner à l'Étape 1.

Mise à jour de l'ensemble actif

Lorsque le pas tronqué active une nouvelle contrainte i^* (cas 2 de l'arrêt) :

- On ajoute i^* à $\mathcal{A}$ et on retire la colonne correspondante de Z_k .
- On **redémarre** les itérations du GC dans le nouvel espace réduit, avec résidu mis à jour.

À l'inverse, aucune contrainte active n'est retirée de $\mathcal{A}$ durant les itérations du GC : les variables fixées en x_k^{GC} le restent jusqu'à la prochaine itération extérieure.

Ce mécanisme garantit que les itérés restent dans $\mathcal{X}$ à chaque sous-itération du GC.

Convergence

Sous les hypothèses suivantes :

- $f \in \mathcal{C}^2$ avec ∇f lipschitzienne,
- $\mathcal{X}$ convexe, fermé, non vide,
- les matrices B_k sont uniformément bornées,

tout point d'accumulation de la suite $\{x_k\}$ générée par l'algorithme de région de confiance avec gradient conjugué projeté tronqué est un **point critique au premier ordre**, i.e. satisfait

$$-\nabla f(x^*) \in N_{\mathcal{X}}(x^*).$$

Si de plus $B_k = \nabla^2 f(x_k)$ (méthode de Newton tronquée), et sous des hypothèses de non-dégénérescence, la convergence est **superlinéaire** au voisinage d'un minimum local.

Voir Lin et Moré (1999), Théorèmes 3.2 et 4.1.

Simplification par la norme infinie

La gestion de la région de confiance et des contraintes de bornes se simplifie considérablement en choisissant la **norme infinie** $\|s\|_\infty = \max_i |[s]_i|$.

En effet, la contrainte de région de confiance $\|s\|_\infty \leq \Delta_k$ s'écrit composante par composante :

$$-\Delta_k \leq [s]_i \leq \Delta_k, \quad \forall i.$$

Elle est donc de la **même nature** que les contraintes de bornes $x_\ell \leq x_k^{GC} + Z_k s^Z \leq x_u$.

On peut ainsi fusionner les deux en définissant des **bornes effectives** sur chaque variable libre j associée à l'indice $i \notin \mathcal{A}(x_k^{GC})$:

$$\ell_j^{\text{eff}} = \max\left([x_\ell]_i - [x_k^{GC}]_i, -\Delta_k\right), \quad u_j^{\text{eff}} = \min\left([x_u]_i - [x_k^{GC}]_i, \Delta_k\right).$$

Les critères d'arrêt 1 (région de confiance) et 2 (contrainte activée) se **fusionnent en un seul** : le pas sort de la boîte $[\ell^{\text{eff}}, u^{\text{eff}}]$.

Pseudocode simplifié (norme infinie)

Étape 0. Calculer bornes effectives ℓ^{eff} , u^{eff} . Poser $s_0^Z = 0$, $r_0 = g_k^Z$, $d_0 = -r_0$, $j = 0$.

Étape 1. Si $\|r_j\| \leq \epsilon_k \|g_k^Z\|$, arrêt : $s^Z \leftarrow s_j^Z$.

Étape 2. Calculer $\kappa_j = d_j^T B_k^Z d_j$.

Si $\kappa_j \leq 0$: calculer

$$\alpha^* = \min_{j'} \left\{ \frac{[\ell^{\text{eff}}]_{j'} - [s_j^Z]_{j'}}{[d_j]_{j'}}, \frac{[u^{\text{eff}}]_{j'} - [s_j^Z]_{j'}}{[d_j]_{j'}} \right\}^+$$

poser $s^Z \leftarrow s_j^Z + \alpha^* d_j$ et arrêt.

Étape 3. Calculer $\alpha_j = r_j^T r_j / \kappa_j$.

Étape 4. Si $s_j^Z + \alpha_j d_j \notin [\ell^{\text{eff}}, u^{\text{eff}}]$: calculer α^* comme ci-dessus (en remplaçant $[s_j^Z]_{j'}$ par sa valeur courante) ; poser $s^Z \leftarrow s_j^Z + \alpha^* d_j$ et arrêt.

Étape 5. Mettre à jour : $s_{j+1}^Z = s_j^Z + \alpha_j d_j$, $r_{j+1} = r_j + \alpha_j B_k^Z d_j$.

Étape 6. Calculer $\beta_j = r_{j+1}^T r_{j+1} / r_j^T r_j$, poser $d_{j+1} = -r_{j+1} + \beta_j d_j$.

Incrémenter j et retourner à l'Étape 1.