

IFT 3515
Fonctions à plusieurs variables
Optimisation avec contraintes
Conditions d'optimalité – 2^e ordre

Fabian Bastin
DIRO
Université de Montréal

Contexte

Nous considérons à nouveau le problème d'optimisation nonlinéaire (PNL) général

$$\begin{aligned} \min_{x \in \mathbb{R}^n} \quad & f(x) \\ \text{t.q.} \quad & g_i(x) = 0, \quad i \in \mathcal{E} \\ & g_i(x) \leq 0, \quad i \in \mathcal{I} \end{aligned}$$

Hypothèse: f et g_i ($i \in \mathcal{E} \cup \mathcal{I}$) sont des fonctions deux fois continûment différentiables.

Chemin de sortie réalisable: rappel

Définition

Soit $x^* \in \mathbb{R}^n$ réalisable et
 $x \in C^2((-\epsilon, \epsilon), \mathbb{R}^n)$ un chemin tel que


$$x(0) = x^*$$

$$d := \frac{d}{dt}x(0) \neq 0$$

$$g_i(x(t)) = 0, \quad i \in \mathcal{E}, \quad t \in (-\epsilon, \epsilon)$$

$$g_i(x(t)) \leq 0, \quad i \in \mathcal{I}, \quad t \in [0, \epsilon)$$

$x(t)$ est *un chemin de sortie réalisable* et d
est *une direction de sortie réalisable* à partir
de x^* .



Optimalité au second ordre

L'analyse d'optimalité au second ordre est basée sur l'observation suivante: si x^* est un minimiseur local du problème de PNL et $x(t)$ est un chemin de sortie réalisable à partir de x^* , alors x^* doit aussi être un minimiseur local pour le problème d'optimisation sous contraintes avec une variable

$$\min_t f(x(t)) \text{ t.q. } t \geq 0.$$

Analysons davantage les directions de sortie réalisables à partir de x^* . La définition implique

$$d^T \nabla g_i(x^*) = \frac{d}{dt} g_i(x(t))|_{t=0} = \begin{cases} \frac{d}{dt} 0 = 0 & i \in \mathcal{E} \\ \lim_{t \rightarrow 0^+} \frac{g_i(x(t)) - 0}{t} & i \in \mathcal{A}(x^*) \cap \mathcal{I} \end{cases}$$

Conditions nécessaires

Dès lors, les conditions suivantes sont nécessaires pour que $d \in \mathbb{R}^n$ soit une direction de sortie réalisable à partir de x^* :

$$d \neq 0$$

$$d^T \nabla g_i(x^*) = 0, \quad i \in \mathcal{E}$$

$$d^T \nabla g_i(x^*) \leq 0, \quad i \in \mathcal{A}(x^*) \cap \mathcal{I}$$

Conditions suffisantes

D'autre part, si la LICQ tient en x^* , du Lemme sur la LICQ, nous avons l'existence d'un chemin de sortie réalisable $x(t)$ à partir de x^* tel que

$$\begin{aligned}x(0) &= x^* \\ \frac{d}{dt}x(0) &= d \\ g_i(x(t)) &= td^T \nabla g_i(x^*), \quad i \in \mathcal{E} \cup \mathcal{A}(x^*), \quad t \in (-\epsilon, \epsilon)\end{aligned}$$

Dès lors, lorsque la LICQ tient, les conditions nécessaires sur d sont aussi suffisantes, et fournissent par conséquent une caractérisation exacte pour que d soit une direction de sortie réalisable à partir de x^* .

Conditions nécessaires d'optimalité au second ordre

Soit x^* un minimum local tel que la LICQ tienne. Les conditions KKT indiquent qu'il existe un vecteur de multiplicateurs de Lagrange λ^* tel que

$$\nabla_x L(x^*, \lambda^*) = 0$$

$$g_i(x^*) = 0, \quad i \in \mathcal{E}$$

$$g_i(x^*) \leq 0, \quad i \in \mathcal{I}$$

$$\lambda_i^* g_i(x^*) = 0, \quad i \in \mathcal{I}$$

$$\lambda_i^* \geq 0, \quad i \in \mathcal{I}$$

où

$$L(x^*, \lambda^*) = f(x^*) + \sum_{i \in \mathcal{E} \cup \mathcal{I}} \lambda_i^* g_i(x^*).$$

Conditions nécessaires d'optimalité au second ordre

Soit $x(t)$ un chemin de sortie réalisable à partir de x^* avec la direction de sortie d , et considérons le problème restreint

$$\begin{aligned} \min & f(x(t)) \\ \text{t.q. } & t \geq 0. \end{aligned}$$

Puisque x^* est un minimiseur local du PNL, $t = 0$ est aussi un minimiseur local du problème restreint.

Du développement de Taylor autour de $t = 0$ et de la règle de la chaîne,

$$\begin{aligned} f(x(t)) &= f(x(0)) + t \left. \frac{d}{dt} f(x(t)) \right|_{t=0} + O(t^2) \\ &= f(x^*) + t \left(\left. \frac{d}{dt} x(t) \right|_{t=0} \right)^T \nabla f(x^*) + O(t^2) \\ &= f(x^*) + t d^T \nabla f(x^*) + O(t^2) \end{aligned}$$

Conditions nécessaires d'optimalité au second ordre

Les conditions KKT donnent $\nabla_x L(x^*, \lambda^*) = 0$, soit

$$\nabla f(x^*) = - \sum_{i \in \mathcal{E} \cup \mathcal{I}} \lambda_i^* \nabla g_i(x^*).$$

En substituant dans le développement de Taylor,

$$f(x(t)) = f(x^*) - t \sum_{i \in \mathcal{E} \cup \mathcal{I}} \lambda_i^* d^T \nabla g_i(x^*) + O(t^2)$$

Pour que $t = 0$ soit minimiseur local du problème restreint, il faut que pour $t \geq 0$ assez petit,

$$-t \sum_{i \in \mathcal{E} \cup \mathcal{I}} \lambda_i^* d^T \nabla g_i(x^*) + O(t^2) \geq 0.$$

Conditions nécessaires d'optimalité au second ordre

Notons que

$$\lambda_i^* d^T \nabla g_i(x^*) = 0, \quad i \in \mathcal{E} \cup (\mathcal{I} \setminus \mathcal{A}(x^*))$$

de sorte que ces termes peuvent être omis.

Mais qu'en est-il des indices $j \in \mathcal{A}(x^*) \cap \mathcal{I}$? Nous savons déjà que $\lambda_j^* d^T \nabla g_j(x^*) \leq 0, \quad j \in \mathcal{A}(x^*)$.

Nous allons distinguer deux cas.

Conditions nécessaires d'optimalité au second ordre

Cas 1: il existe un indice $j \in \mathcal{A}(x^*)$ tel que $\lambda_j^* d^T \nabla g_j(x^*) < 0$.

Alors, pour tout $0 < t \ll 1$,

$$\begin{aligned} f(x(t)) &= f(x^*) - t \sum_{i \in \mathcal{E} \cup \mathcal{I}} \lambda_i^* d^T \nabla g_i(x^*) + O(t^2) \\ &\geq f(x^*) - t \lambda_j^* d^T \nabla g_j(x^*) + O(t^2) \\ &> f(x^*) \end{aligned}$$

Dès lors, dans ce cas, f est strictement croissante le long du chemin $x(t)$ pour t suffisamment petit, même si $\frac{d^2}{dt^2} f(x(0))$ était négatif.


Conditions nécessaires d'optimalité au second ordre

Cas 2:

$$\lambda_i^* d^T \nabla g_i(x^*) = 0, \quad i \in \mathcal{E} \cup \mathcal{I}.$$

L'argument de Cas 1 ne s'applique plus. Nous savons seulement que $\frac{d}{dt}f(x(t)) = 0$: x^* est un point stationnaire du problème restreint. Mais il pourrait s'agir d'un maximiseur local ou d'un point selle!

Les dérivées secondes $\frac{d^2}{dt^2}f(x(t))$ déterminent si $t = 0$ est un minimiseur local: si $d^T \nabla_{xx}^2 L(x^*, \lambda^*) d < 0$, alors x^* n'est pas un minimum local.



Profils de $f(x(t))$ pour $t \geq 0$
selon le signe de $\frac{d^2}{dt^2}f(x(0))$

Conditions nécessaires d'optimalité au second ordre

Nous noterons

$$N^+ = \left\{ d \neq 0 \left| \begin{array}{ll} d^T \nabla g_i(x^*) = 0, & i \in \mathcal{E} \cup \{j \in \mathcal{A}(x^*) \cap \mathcal{I} \mid \lambda_j^* > 0\} \\ d^T \nabla g_i(x^*) \leq 0, & \{i \in \mathcal{A}(x^*) \cap \mathcal{I} \mid \lambda_i^* = 0\} \end{array} \right. \right\}$$

Dès lors, $d \in N^+$ implique $\lambda_i^* d^T \nabla g_i(x^*) = 0$, $i \in \mathcal{E} \cup \mathcal{I}$.

Théorème (Conditions nécessaires d'optimalité au second ordre)

Soit x^ un minimiseur local du PNL où la LICQ tient. Soit $\lambda^* \in \mathbb{R}^m$ un vecteur de multiplicateurs de Lagrange tel que (x^*, λ^*) satisfaisant les conditions KKT. Alors nous avons*

$$d^T \nabla_{xx}^2 L(x^*, \lambda^*) d \geq 0$$

pour tout $d \in N^+$.

Géométrie de N^+


Sous LICQ, le cône tangent à $\mathcal{X}$ en x^* est:

$$T_{\mathcal{X}}(x^*) = \left\{ d \left| \begin{array}{l} d^T \nabla g_i = 0, \quad i \in \mathcal{E} \\ d^T \nabla g_i \leq 0, \quad i \in \mathcal{A}(x^*) \cap \mathcal{I} \end{array} \right. \right\}$$

En comparant avec la définition de N^+ terme à terme: tout $d \in N^+$ satisfait $d^T \nabla g_i = 0$ pour $i \in \mathcal{E}$ et $d^T \nabla g_i \leq 0$ pour $i \in \mathcal{A}(x^*) \cap \mathcal{I}$, donc $d \in T_{\mathcal{X}}(x^*)$.

Ainsi $N^+ \subseteq T_{\mathcal{X}}(x^*)$.

Sous complémentarité stricte ($\lambda_j^* \neq 0$ pour tout $j \in \mathcal{A}(x^*) \cap \mathcal{I}$), toutes les contraintes actives imposent $d^T \nabla g_j = 0$: les deux ensembles coïncident et $N^+ = T_{\mathcal{X}}(x^*)$.



Preuve

Soit $d \in N^+$ et soit $x(\cdot) \in C^2((-\epsilon, \epsilon), \mathbb{R}^n)$ un chemin de sortie réalisable à partir de x^* correspondant à d (dont l'existence est garantie par la LICQ).

Par le Lemme sur la LICQ, $g_i(x(t)) = td^T \nabla g_i(x^*)$ pour $i \in \mathcal{E} \cup \mathcal{A}(x^*)$. Pour $i \in \mathcal{I} \setminus \mathcal{A}(x^*)$, la complémentarité KKT donne $\lambda_i^* = 0$. Enfin, $d \in N^+$ implique $\lambda_i^* d^T \nabla g_i(x^*) = 0$ pour tout $i \in \mathcal{E} \cup \mathcal{I}$. Dès lors:

$$\begin{aligned} L(x(t), \lambda^*) &= f(x(t)) + \sum_{i \in \mathcal{E} \cup \mathcal{I}} \lambda_i^* g_i(x(t)) \\ &= f(x(t)) + \sum_{i \in \mathcal{E} \cup \mathcal{I}} \lambda_i^* \cdot td^T \nabla g_i(x^*) \quad (\text{Lemme LICQ} + \text{complémentarité}) \\ &= f(x(t)) + t \sum_{i \in \mathcal{E} \cup \mathcal{I}} \lambda_i^* d^T \nabla g_i(x^*) = f(x(t)) \quad (\text{car } d \in N^+) \end{aligned}$$

Preuve: règle de la chaîne au second ordre

Posons $h(t) := L(x(t), \lambda^*) = f(x(t))$. Par la règle de la chaîne:

$$\frac{d}{dt}h(t) = \nabla_x L(x(t), \lambda^*)^T \frac{d}{dt}x(t)$$

En dérivant une seconde fois:

$$\begin{aligned} \frac{d^2}{dt^2}h(t) &= \left(\frac{d}{dt}x(t) \right)^T \nabla_{xx}^2 L(x(t), \lambda^*) \frac{d}{dt}x(t) \\ &\quad + \nabla_x L(x(t), \lambda^*)^T \frac{d^2}{dt^2}x(t) \end{aligned}$$

En $t = 0$, avec $\frac{d}{dt}x(0) = d$:

$$\begin{aligned} \frac{d}{dt}h(0) &= \nabla_x L(x^*, \lambda^*)^T d \\ \frac{d^2}{dt^2}h(0) &= d^T \nabla_{xx}^2 L(x^*, \lambda^*) d + \nabla_x L(x^*, \lambda^*)^T \frac{d^2}{dt^2}x(0) \end{aligned}$$

Preuve: développement de Taylor au second ordre

Le développement de Taylor

$$h(t) = h(0) + t \frac{d}{dt} h(0) + \frac{t^2}{2} \frac{d^2}{dt^2} h(0) + O(t^3)$$

donne donc

$$\begin{aligned} f(x(t)) &= L(x^*, \lambda^*) + t \nabla_x L(x^*, \lambda^*)^T d \\ &\quad + \frac{t^2}{2} \left(d^T \nabla_{xx}^2 L(x^*, \lambda^*) d + \nabla_x L(x^*, \lambda^*)^T \frac{d^2}{dt^2} x(0) \right) + O(t^3) \end{aligned}$$

Preuve

Les conditions KKT impliquent

$$\nabla_x L(x^*, \lambda^*) = 0$$

Dès lors

$$f(x(t)) = L(x^*, \lambda^*) + \frac{t^2}{2} d^T \nabla_{xx}^2 L(x^*, \lambda^*) d + O(t^3)$$

et, des conditions KKT, $L(x^*, \lambda^*) = f(x^*) + \sum_{i \in \mathcal{E} \cup \mathcal{I}} \lambda_i^* g_i(x^*) = f(x^*)$, puisque $g_i(x^*) = 0$ pour $i \in \mathcal{E}$ et $\lambda_i^* g_i(x^*) = 0$ pour $i \in \mathcal{I}$ (complémentarité)

Si $d^T \nabla_{xx}^2 L(x^*, \lambda^*) d < 0$ alors pour t suffisamment petit, $f(x(t)) < f(x^*)$, contredisant l'hypothèse que x^* est un minimiseur local.

Dès lors, nous devons avoir

$$d^T \nabla_{xx}^2 L(x^*, \lambda^*) d \geq 0$$

Conditions suffisantes d'optimalité au second ordre

Théorème (Conditions suffisantes d'optimalité au second ordre)

Soit $(x^, \lambda^*) \in \mathbb{R}^n \times \mathbb{R}^m$ satisfaisant les conditions KKT, et sous une hypothèse de qualification de contrainte, si*

$$d^T \nabla_{xx}^2 L(x^*, \lambda^*) d > 0$$

pour toute direction $d \in N^+$. Alors x^ est un minimiseur local strict.*

Preuve

Supposons par contradiction que x^* n'est pas un minimiseur local. Il existe alors une séquence de points réalisables $\{x_k\}$, $k = 1, \dots$, telle que $x_k \neq x^*$, $\lim_{k \rightarrow \infty} x_k = x^*$ et $f(x_k) \leq f(x^*)$ pour tout $k \in \mathbb{N}$.

La séquence $d_k := \frac{x_k - x^*}{\|x_k - x^*\|}$ tient sur la sphère unité, qui est un ensemble compact. On peut donc en extraire une sous-séquence $\{d_{k_i}\}$ convergeant vers une direction limite d , avec $d \neq 0$. Sans perte de généralité, on pose $k_i = i$.

Preuve

Vérifions que $d \in N^+$. Considérons tout d'abord les contraintes d'égalité. $\forall i \in \mathcal{E}$, en utilisant le développement de Taylor, nous avons

$$\begin{aligned} 0 &= \frac{g_i(x_k)}{\|x_k - x^*\|} \\ &= \frac{1}{\|x_k - x^*\|} \left(g_i(x^*) + \|x_k - x^*\| \nabla g_i(x^*)^T d_k + O(\|x_k - x^*\|^2) \right) \\ &= \nabla g_i(x^*)^T d_k + O(\|x_k - x^*\|) \end{aligned}$$

En faisant tendre k vers l'infini, nous obtenons

$$\nabla g_i(x^*)^T d = 0$$

Preuve

$\forall i \in \mathcal{A}(x^*) \cap \mathcal{I}$, en utilisant le développement de Taylor, nous avons de manière similaire

$$\begin{aligned} 0 &\geq \frac{g_i(x_k)}{\|x_k - x^*\|} \\ &= \frac{1}{\|x_k - x^*\|} \left(g_i(x^*) + \|x_k - x^*\| \nabla g_i(x^*)^T d_k + O(\|x_k - x^*\|^2) \right) \\ &= \nabla g_i(x^*)^T d_k + O(\|x_k - x^*\|) \end{aligned}$$

En faisant tendre k vers l'infini, nous obtenons

$$\nabla g_i(x^*)^T d \leq 0$$

Ainsi, d est une direction de sortie réalisable. Montrons que $d \in N^+$.

Preuve

Si $d \notin N^+$, alors $\exists j \in \mathcal{A}(x^*) \cap \mathcal{I}$ tel que

$$\lambda_j^* \nabla g_j(x^*)^T d < 0$$

En vertu du développement de Taylor,

$$\begin{aligned} \lambda_j^* g_j(x_k) &= \lambda_j^* g_j(x^*) + \lambda_j^* \|x_k - x^*\| \nabla g_j(x^*)^T d_k + O(\|x_k - x^*\|^2) \\ &= \lambda_j^* \|x_k - x^*\| \nabla g_j(x^*)^T d_k + O(\|x_k - x^*\|^2) \end{aligned}$$

Dès lors

$$\begin{aligned} L(x_k, \lambda^*) &= f(x_k) + \sum_{i \in \mathcal{E} \cup \mathcal{I}} \lambda_i^* g_i(x_k) \\ &\leq f(x_k) + \lambda_j^* g_j(x_k) \\ &= f(x_k) + \lambda_j^* \|x_k - x^*\| \nabla g_j(x^*)^T d_k + O(\|x_k - x^*\|^2) \end{aligned}$$

Preuve

D'autre part, le développement de Taylor de $L(x_k, \lambda^*)$ autour de (x^*, λ^*) donne

$$\begin{aligned} L(x_k, \lambda^*) &= L(x^*, \lambda^*) + \|x_k - x^*\| d_k^T \nabla_x L(x^*, \lambda^*) \\ &\quad + \frac{\|x_k - x^*\|^2}{2} d_k^T \nabla_{xx}^2 L(x^*, \lambda^*) d_k + O(\|x_k - x^*\|^3) \end{aligned}$$

De part les conditions KKT, $\nabla_x L(x^*, \lambda^*) = 0$ et $L(x^*, \lambda^*) = f(x^*)$. Dès lors, nous obtenons

$$L(x_k, \lambda^*) = f(x^*) + \frac{\|x_k - x^*\|^2}{2} d_k^T \nabla_{xx}^2 L(x^*, \lambda^*) d_k + O(\|x_k - x^*\|^3)$$

En combinant ces expressions,

$$\begin{aligned} f(x_k) &\geq L(x_k, \lambda^*) - \lambda_j^* \|x_k - x^*\| \nabla g_j(x^*)^T d_k + O(\|x_k - x^*\|^2) \\ &= f(x^*) - \lambda_j^* \|x_k - x^*\| \nabla g_j(x^*)^T d_k + O(\|x_k - x^*\|^2) \end{aligned}$$

et pour k assez grand, $f(x_k) > f(x^*)$ contredisant nos hypothèses de travail.

Preuve

Ainsi $d \in N^+$, et des hypothèses du théorème, nous avons

$$d^T \nabla_{xx}^2 L(x^*, \lambda^*) d > 0.$$

D'autre part, des conditions KKT et $d \in N^+$,

$$\nabla f(x^*)^T d = -d^T \sum_{i \in \mathcal{E} \cup \mathcal{I}} \lambda_i^* \nabla g_i(x^*) = \sum_{i \in \mathcal{E} \cup \mathcal{I}} \lambda_i^* (-d^T \nabla g_i(x^*)) = 0$$

De plus, de nos hypothèses de départ et des conditions KKT,

$$f(x^*) \geq f(x_k) \geq f(x_k) + \sum_{i \in \mathcal{E} \cup \mathcal{I}} \lambda_i^* g_i(x_k) = L(x_k, \lambda^*)$$

et, reprenant le développement de $L(x_k, \lambda^*)$

$$f(x^*) \geq f(x^*) + \frac{\|x_k - x^*\|^2}{2} d_k^T \nabla_{xx}^2 L(x^*, \lambda^*) d_k + O(\|x_k - x^*\|^3)$$

Preuve

Il s'ensuit

$$d_k^T \nabla_{xx}^2 L(x^*, \lambda^*) d_k \leq O(\|x_k - x^*\|)$$

en passant à la limite comme $k \rightarrow \infty$

$$d^T \nabla_{xx}^2 L(x^*, \lambda^*) d \leq 0$$

Ceci contredit l'hypothèse du théorème

$$d^T \nabla_{xx}^2 L(x^*, \lambda^*) d > 0$$

et donc l'hypothèse d'existence de la séquence $\{x_k\}$ ne tient pas. Dès lors, x^* est minimiseur local.

Complémentarité stricte

Il est courant, et commode, de supposer que la condition de complémentarité stricte s'applique. Celle-ci requiert que le multiplicateur de Lagrange ne peut s'annuler pour une contrainte active, i.e.

$$\lambda_j^* \neq 0 \quad \forall j \in \mathcal{A}(x^*) \cap \mathcal{I}$$

La complémentarité stricte permet de réexprimer N^+ de manière très commode. Rappelons que

$$N^+ = \left\{ d \neq 0 \left| \begin{array}{ll} d^T \nabla g_i(x^*) = 0, & i \in \mathcal{E} \cup \{j \in \mathcal{A}(x^*) \cap \mathcal{I} \mid \lambda_j^* > 0\} \\ d^T \nabla g_i(x^*) \leq 0, & \{i \in \mathcal{A}(x^*) \cap \mathcal{I} \mid \lambda_i^* = 0\} \end{array} \right. \right\}$$

sous la complémentarité stricte, nous avons

$$N^+ = \left\{ d \neq 0 \mid d^T \nabla g_i(x^*) = 0, i \in \mathcal{A}(x^*) \right\}$$

Complémentarité stricte

Autrement dit, d appartient au noyau du Jacobien des contraintes actives:

$$d \in \ker(J), \quad J = (\nabla g_i(x^*)^T, i \in \mathcal{A}(x^*))$$

Comme

$$d \in N^+ \Rightarrow \lambda_i^* d^T \nabla g_i(x^*) = 0, \quad i \in \mathcal{E} \cup \mathcal{I},$$

nous avons également

$$d \in N^+ \Leftrightarrow \lambda_i^* d^T \nabla g_i(x^*) = 0, \quad i \in \mathcal{E} \cup \mathcal{I},$$